

UNIVERSIDAD DE LA CUENCA DEL PLATA

Facultad de Ingeniería, Tecnología y Arquitectura

Ingeniería en Sistemas de Información

LLMOps aplicado a sistemas RAG

*Arquitectura basada en evaluación híbrida para la detección de drift semántico y actualización de
bases vectoriales*

Avance Proyecto Final de Grado

Estudiante: Sanchez Joaquin Sebastian: 45.452.416 - Joassanchez03@gmail.com

Carrera: Ingeniería en Sistemas de Información

Cátedra: Gestión de Proyectos

Año: Quinto

Profesor: Lic. Luján, Estefanía

Introducción

La Inteligencia Artificial Generativa, impulsada por modelos de lenguaje de gran escala (LLM), ha transformado la forma en que las organizaciones acceden, procesan y utilizan la información. Estos modelos permiten interactuar en lenguaje natural y automatizar procesos, aunque presentan limitaciones relacionadas con la actualización y precisión del conocimiento, lo que puede derivar en respuestas incorrectas o desactualizadas.

En este contexto, los sistemas de Generación Aumentada por Recuperación (RAG) surgen como una solución que integra modelos de lenguaje con bases de conocimiento externas, permitiendo generar respuestas más contextualizadas y fundamentadas. Sin embargo, estos sistemas introducen nuevos desafíos asociados a la gestión, actualización y control del conocimiento, especialmente en entornos donde la información evoluciona constantemente.

Para abordar estas limitaciones, el enfoque LLMOps propone prácticas orientadas a la supervisión, evaluación y mantenimiento continuo de sistemas basados en modelos de lenguaje.

En este marco, el presente trabajo propone el diseño de una arquitectura LLMOps aplicada a sistemas RAG, orientada a mejorar la calidad y confiabilidad de las respuestas mediante la detección de degradación del conocimiento y la actualización controlada de bases vectoriales.

Descripción del Proyecto

Desarrollar una arquitectura de operaciones para Modelos de Lenguaje Grande (LLMOps) que supervise continuamente un sistema de Generación Aumentada por Recuperación (RAG). La propuesta incorpora un enfoque de evaluación híbrida, combinando métricas determinísticas, evaluación semántica mediante modelos de lenguaje (LLM-as-a-judge) y señales derivadas del comportamiento del sistema.

Ante la detección de degradación en la calidad de las respuestas —ya sea por pérdida de relevancia del contexto recuperado (Data Drift) o cambios en las consultas de los usuarios (Query Drift)—, la arquitectura orquesta de manera automatizada la recolección, procesamiento e ingesta de nueva información, permitiendo la actualización controlada de la base de conocimiento vectorial.

Asimismo, se incorpora una capa de interacción y observabilidad que permite la supervisión del sistema y la intervención del usuario en el ciclo de vida del conocimiento, alineándose con un enfoque human-in-the-loop.

Solución Académica

Se propone el diseño e implementación de una arquitectura de tipo closed-loop LLMOps, orientada a la supervisión continua y adaptación dinámica del conocimiento en sistemas RAG. La solución introduce un sistema de evaluación basado en múltiples señales que permite estimar la calidad de las respuestas generadas a partir de:

- Métricas de similitud y cobertura del contexto (basadas en embeddings),
- Evaluación semántica mediante modelos de lenguaje (LLM-as-a-judge),
- Señales derivadas del comportamiento del sistema.

Estas señales son integradas mediante una función de calidad agregada Q , que permite obtener un puntaje unificado para cada interacción:

$$Q = w_1 * S_{sim} + w_2 * S_{cov} + w_3 * S_{llm} + w_4 * S_{user}$$

Donde:

- | | |
|--------------------------------------|-----------------------------------|
| - S_{sim} : Similitud Semántica | - S_{llm} : Evaluación del LLM |
| - S_{cov} : Cobertura del contexto | - S_{user} : Señales de usuario |

Las métricas son normalizadas en el rango $[0, 1]$ y los pesos w_i son definidos experimentalmente.

Cuando el puntaje agregado de calidad cae por debajo de un umbral definido, se activa un mecanismo de decisión que determina la necesidad de actualización del conocimiento. En dichos casos, un orquestador de flujos de trabajo (por ejemplo, Apache Airflow) ejecuta procesos de extracción, transformación y carga (ETL), generando nuevos embeddings y reconstruyendo la base vectorial.

La actualización se realiza mediante un enfoque controlado, priorizando la consistencia y validación del nuevo conocimiento antes de su despliegue, evitando así riesgos asociados a automatizaciones no supervisadas.

Misión

Proveer a las organizaciones de una arquitectura LLMOps robusta y escalable que supervise de forma continua los sistemas RAG, garantizando la vigencia y precisión del conocimiento mediante evaluación híbrida y procesos de actualización controlada, con el fin de mitigar el riesgo de alucinaciones y asegurar respuestas confiables en entornos críticos.

Visión

Constituirse como un referente en la gobernanza y gestión del ciclo de vida del conocimiento en sistemas de Inteligencia Artificial Generativa, promoviendo entornos en los que los modelos de lenguaje operen con altos niveles de transparencia, trazabilidad y confiabilidad.

Objetivo General

Diseñar, implementar y validar una arquitectura LLMOps end-to-end capaz de detectar la degradación del conocimiento en sistemas RAG mediante evaluación híbrida, y ejecutar procesos de actualización controlada de la base de conocimiento, garantizando la calidad y confiabilidad de las respuestas generadas.

Objetivos Específicos

1. **Desarrollar un pipeline de ingesta de conocimiento modular y escalable:** Construir un sistema de extracción, procesamiento (chunking), validación y vectorización de documentos no estructurados, que permita integrar múltiples fuentes de datos, incluyendo mecanismos automáticos y carga manual asistida, hacia una base de conocimiento vectorial.
2. **Implementar un motor de evaluación híbrida para sistemas RAG:** Integrar métricas determinísticas, evaluación semántica mediante modelos de lenguaje (LLM-as-a-judge) y señales derivadas del comportamiento del usuario, con el fin de medir la calidad, relevancia y consistencia de las respuestas generadas.
3. **Diseñar un mecanismo de detección de degradación del conocimiento (drift):** Desarrollar una función de agregación de métricas que permita identificar pérdidas significativas en la calidad de las respuestas, incorporando una clasificación de fallos que distinga entre errores de recuperación, generación, drift del conocimiento y drift en las consultas.
4. **Implementar un mecanismo de actualización controlada de la base de conocimiento:** Diseñar e integrar procesos orquestados de actualización que permitan incorporar nueva información mediante pipelines ETL, aplicando criterios de validación y consistencia previos al despliegue, evitando la propagación de conocimiento incorrecto.
5. **Diseñar e implementar una capa de interacción y observabilidad del sistema:** Desarrollar una interfaz conversacional para la interacción con el sistema RAG y un dashboard de

monitoreo que permita visualizar métricas clave de desempeño, incluyendo el puntaje agregado de calidad (Q), facilitando la supervisión y la interpretación de resultados.

6. **Validar la arquitectura mediante experimentación:** Simular escenarios de *Data Drift* y *Query Drift* mediante la incorporación de información desactualizada utilizando un corpus documental del sector legal (normativas del Boletín Oficial), evaluando la capacidad del sistema para detectar la degradación, orquestar su actualización y mejorar la precisión de las respuestas en un entorno normativo dinámico.

Alcance y Limitaciones

El presente trabajo se centra en el diseño, implementación y validación de una arquitectura LLMOps aplicada a sistemas de Generación Aumentada por Recuperación (RAG), con énfasis en la detección de *drift* del conocimiento y la actualización controlada de bases de conocimiento vectorial.

La arquitectura diseñada posee una naturaleza **agnóstica al dominio**, lo que permite su integración y despliegue en cualquier organización o industria que requiera mantener bases de conocimiento institucionales actualizadas. Sin embargo, para garantizar un proceso de validación empírica con el rigor técnico necesario, se ha seleccionado el **sector legal y normativo** como entorno controlado para las pruebas. Esta elección responde a la complejidad intrínseca de sus documentos, la constante actualización de sus normativas y la sensibilidad crítica de sus respuestas ante las alucinaciones, convirtiéndolo en el escenario de prueba (o mercado piloto) ideal para medir la eficacia del sistema bajo altos niveles de exigencia.

El alcance de la propuesta se limita a la gestión del conocimiento en la etapa de recuperación (RAG), sin contemplar modificaciones estructurales en los modelos de lenguaje subyacentes. En este sentido, se establecen las siguientes limitaciones:

- **Ausencia de fine-tuning de modelos de lenguaje:** La adaptación del sistema se realiza exclusivamente mediante la actualización de la base de conocimiento, sin aplicar técnicas de ajuste fino sobre los modelos.
- **Procesamiento no orientado a tiempo real estricto:** La actualización del conocimiento se implementa mediante esquemas batch o micro-batch, en función de la disponibilidad y frecuencia de las fuentes de datos, priorizando la validación previa a su incorporación.
- **Restricción al procesamiento textual:** La arquitectura se limita al tratamiento de información en formato texto, excluyendo datos multimodales como imágenes, audio o video.
- **Validación en un dominio específico:** La evaluación del sistema se realiza en un entorno controlado (Normativas del boletín oficial), lo que permite simular escenarios de drift, aunque puede limitar la generalización de los resultados a otros dominios.
- **Automatización parcialmente supervisada:** No se contempla una automatización completamente autónoma, priorizando un enfoque con mecanismos de validación e intervención del usuario (human-in-the-loop) para garantizar la calidad del conocimiento incorporado.
- **No optimización para entornos de alta escala:** El sistema no está diseñado con foco en la latencia mínima ni en el rendimiento a gran escala, sino en la calidad, trazabilidad y control del conocimiento.

Monetización y Valor de Negocio

Si bien el presente trabajo posee un enfoque académico, la arquitectura propuesta presenta un modelo claro de aplicación corporativa **mediante un esquema de Licenciamiento de Software (On-Premise) y provisión de infraestructura dedicada (Marca Blanca)**. En este modelo, la

arquitectura LLMOps y el sistema RAG se empaquetan y despliegan directamente en los servidores locales o nubes privadas del cliente, orientándose a sectores de alta criticidad como el **Poder Judicial, organismos del Estado y grandes estudios jurídicos corporativos**.

Este enfoque garantiza la **soberanía de los datos y el estricto cumplimiento normativo (compliance)**, elementos innegociables en el ecosistema LegalTech y gubernamental, asegurando que la jurisprudencia, expedientes y estrategias confidenciales nunca queden expuestos en nubes públicas de terceros. A través del dashboard de observabilidad, la organización no solo interactúa con el modelo, sino que ejerce un rol de auditoría mediante el mecanismo *human-in-the-loop*, validando el conocimiento crítico antes de su impacto en el sistema.

Comercialmente, **el servicio se estructura en dos vías de ingresos corporativos (B2B/B2G): un costo de implementación inicial (Setup Fee)**, que contempla la conexión del pipeline de ingesta a los repositorios documentales del cliente, **y una Licencia Anual** que garantiza el derecho de uso del motor de evaluación de calidad, el soporte técnico y las actualizaciones de la arquitectura. De este modo, la propuesta no solo aborda un problema técnico complejo, sino que presenta ventajas competitivas frente a soluciones enlatadas al ofrecer un sistema a medida, auditable y con altos márgenes de rentabilidad.

Analisis FODA

El análisis FODA (Fortalezas, Oportunidades, Debilidades y Amenazas) constituye una herramienta estratégica que permite evaluar la viabilidad y el posicionamiento de una propuesta, considerando tanto factores internos como externos. En el contexto del presente trabajo, este análisis se aplica a la arquitectura LLMOps propuesta para sistemas de Generación Aumentada por Recuperación (RAG), con el objetivo de identificar sus ventajas, limitaciones y el entorno en el cual se inserta.

Fortalezas (Internas)

En relación con los factores internos positivos, la propuesta presenta diversas fortalezas relevantes:

1. **Carácter innovador:** Integra conceptos emergentes como LLMOps, sistemas RAG y mecanismos de detección de drift semántico, áreas en desarrollo tanto a nivel académico como industrial, lo que posiciona la propuesta como una solución de vanguardia.
2. **Abordaje de un problema crítico:** Se enfoca en la obsolescencia del conocimiento en sistemas basados en modelos de lenguaje, problemática que impacta directamente en la calidad y confiabilidad de las respuestas.
3. **Enfoque integral de la arquitectura:** Contempla el ciclo completo de gestión del conocimiento, incluyendo ingesta, evaluación, detección de degradación y actualización controlada, lo que aporta coherencia y aplicabilidad práctica.
4. **Modelo de evaluación híbrida:** Combina métricas determinísticas, evaluación semántica mediante modelos de lenguaje (LLM-as-a-judge) y señales del usuario, permitiendo una medición más robusta y alineada con el uso real.
5. **Uso de tecnologías consolidadas:** Se apoya en herramientas ampliamente adoptadas, muchas de ellas open source, reduciendo riesgos de implementación y favoreciendo la reproducibilidad.
6. **Enfoque de observabilidad y control:** Incorpora mecanismos de monitoreo e intervención humana (human-in-the-loop), mejorando la trazabilidad y confiabilidad del sistema.
7. **Alineación con tendencias y modelo corporativo:** Presenta altas barreras de entrada para la competencia masiva al ofrecer un modelo de licenciamiento corporativo (On-Premise) que prioriza la privacidad y soberanía de los datos sensibles.

Oportunidades (Externas)

En cuanto a los factores externos favorables, se identifican las siguientes oportunidades:

1. **Crecimiento de la inteligencia artificial generativa:** La adopción creciente de sistemas RAG genera una demanda sostenida de soluciones que garanticen la actualización del conocimiento.
2. **Ausencia de estándares en LLMOps:** La falta de marcos consolidados abre espacio para propuestas innovadoras con impacto académico y profesional.
3. **Demanda de confiabilidad y gobernanza:** Las organizaciones demandan sistemas trazables y confiables, especialmente en dominios críticos.
4. **Potencial de evolución:** La propuesta puede derivar en alianzas con *Software Factories* locales, productos tecnológicos o implementaciones reales en el Estado.
5. **Adaptabilidad:** La arquitectura puede aplicarse en distintos contextos, facilitando su escalabilidad e integración.

Debilidades (Internas)

En relación con los factores internos que pueden limitar la propuesta, se identifican las siguientes debilidades:

1. **Alta complejidad técnica:** La integración de múltiples componentes incrementa la dificultad de implementación y mantenimiento.
2. **Dependencia tecnológica:** El uso de servicios externos puede afectar la estabilidad y sostenibilidad del sistema.
3. **Subjetividad en la evaluación:** El uso de LLM como evaluadores puede introducir sesgos e inconsistencias.
4. **Sensibilidad a parámetros:** La calibración de pesos y umbrales requiere validación experimental rigurosa.

5. **Limitaciones de infraestructura:** Si bien el prototipo académico se despliega en recursos acotados (VPS), el modelo de negocio mitiga esto delegando la carga computacional a la infraestructura y servidores propios del cliente.
6. **Dominio acotado de validación:** La evaluación en un contexto específico puede limitar la generalización.
7. **Ausencia de fine-tuning:** Puede restringir la adaptabilidad en determinados escenarios.

Amenazas (Externas)

En relación con los factores externos que podrían afectar negativamente la propuesta, se identifican las siguientes amenazas:

1. **Evolución tecnológica acelerada:** Nuevas herramientas pueden volver parcialmente obsoleta la solución.
2. **Dependencia de proveedores:** Cambios en costos o políticas pueden impactar la operatividad.
3. **Competencia de grandes empresas:** Existen soluciones comerciales en la nube más maduras, aunque con limitaciones en la soberanía de datos locales.
4. **Complejidad en los ciclos de venta:** Al orientarse a un mercado corporativo (B2B/B2G) de alto valor (Enterprise), los procesos de adquisición, contratos y licitaciones públicas pueden ser burocráticos y extensos.
5. **Riesgos de implementación:** Problemas de disponibilidad o compatibilidad al instalar la arquitectura en servidores de terceros
6. **Dificultad de evaluación objetiva:** La falta de métricas estandarizadas en lenguaje natural representa un desafío.

Análisis estratégico de Competitividad

Matriz SPACE (Strategic Position and Action Evaluation)

Como complemento al análisis FODA , se desarrolla la Matriz SPACE, una herramienta estratégica que permite determinar la postura competitiva más adecuada para la arquitectura LLMOps propuesta. Esta matriz evalúa el sistema a través de cuatro dimensiones fundamentales: dos de carácter interno (Ventaja Competitiva y Fuerza Financiera) y dos de carácter externo (Fuerza de la Industria y Estabilidad del Entorno).

- ***Ventaja Competitiva (VC):*** Esta dimensión evalúa las fortalezas y debilidades tecnológicas del sistema en relación con posibles alternativas existentes. Para su medición, se utiliza una escala que varía de -1 (excelente o fuerte) a -6 (muy débil).
- ***Fuerza Financiera (FF):*** Analiza la viabilidad económica de la propuesta, considerando aspectos como los costos de infraestructura y el potencial de monetización. Esta dimensión se mide en una escala de +1 (muy débil) a +6 (muy fuerte).
- ***Fuerza de la Industria (FI):*** Mide el atractivo y el potencial de crecimiento del sector en el que se inserta la propuesta. Se utiliza una escala de +1 (Muy mala/Débil) a +6 (Excelente/Fuerte).
- ***Estabilidad del Entorno (EE):*** Evalúa el grado de incertidumbre del contexto, considerando factores como la volatilidad del mercado, la evolución tecnológica y los riesgos asociados. En este caso, se emplea una escala de -1 (muy estable) a -6 (muy inestable).

La metodología de aplicación consiste en asignar una puntuación a cada variable crítica identificada en el análisis previo, calcular el promedio de cada dimensión y, posteriormente, determinar el vector direccional resultante. Este vector permite ubicar la propuesta en un plano cartesiano, definiendo así su posicionamiento estratégico.

Evaluación de las Dimensiones Internas

Tabla 1. Evaluación de las dimensiones internas de la Matriz SPACE

<i>Ventaja Competitiva (VC)</i>		<i>Fuerza Financiera (FF)</i>	
Variable Evaluada	Puntuación	Variable Evaluada	Puntuación
Innovación Tecnológica	-1	Modelo de Monetización (Licencias B2B)	+5
Evaluación Híbrida	-1	Estructura de Costos Base	+4
Enfoque Integral	-2	Restricciones de Hardware Delegado	+2
Subjetividad de Evaluación	-3	Riesgo de Escalabilidad	+2
Dependencia Tecnológica	-4	–	–
Promedio VC	-2.20	Promedio FF	+3.25

Fuente: Elaboración propia basada en el modelo SPACE (Rowe et al., 1994).

Evaluación de las Dimensiones Externas

Tabla 2. Evaluación de las dimensiones externas de la Matriz SPACE

<i>Fuerza de la Industria (FI)</i>		<i>Estabilidad del Entorno (EE)</i>	
Variable Evaluada	Puntuación	Variable Evaluada	Puntuación
Demanda del Mercado	+6	Competencia Comercial	-4
Gobernanza de IA	+5	Estabilidad de Proveedores	-4
Madurez del Estándar	+5	Evolución Tecnológica	-5

Promedio FI	+5.33	Promedio EE	-4.33
-------------	-------	-------------	-------

Fuente: Elaboración propia basada en el modelo SPACE (Rowe et al., 1994).

Cálculo del Vector Direccional y Postura Estratégica

Para determinar la posición de la propuesta dentro de la Matriz SPACE, se procede a calcular el vector direccional a partir de la suma de las puntuaciones promedio de las dimensiones correspondientes a cada eje.

El **eje X**, que representa la posición estratégica combinada entre factores internos y externos, se obtiene a partir de la suma de la Fuerza de la Industria (FI) y la Ventaja Competitiva (VC):

$$X = (+ 5.33) + (- 2.20) = + 3.13$$


Por su parte, el **eje Y**, que refleja la posición financiera y las condiciones del entorno, se calcula mediante la suma de la Fuerza Financiera (FF) y la Estabilidad del Entorno (EE):

$$Y = (+ 3.25) + (- 4.33) = - 1.08$$

A partir de estos resultados, se obtienen las coordenadas finales del sistema en el plano cartesiano:

$$(X,Y) = (+ 3.13, - 1.08)$$

Figura 1. Posicionamiento estratégico en la Matriz SPACE



Fuente: Elaboración propia basada en el modelo SPACE (Rowe et al., 1994).

Conclusión del Análisis SPACE

Las coordenadas obtenidas (+3.13, -1.08) ubican a la propuesta en el **cuadrante inferior derecho** de la Matriz SPACE, lo que corresponde a un **perfil competitivo**. La propuesta se posiciona evidenciando una combinación de alto potencial de crecimiento en la industria (enfocada en entornos críticos) y una ventaja competitiva relevante.

Este posicionamiento indica que la arquitectura LLMOps propuesta se desarrolla en una industria con alto potencial de crecimiento y presenta ventajas competitivas relevantes, principalmente asociadas a su carácter innovador, a la incorporación de un modelo de evaluación híbrida y **al enfoque de despliegue On-Premise**. Estas características le otorgan una base sólida para diferenciarse dentro del mercado.

Sin embargo, el análisis también evidencia que el entorno en el cual se inserta es altamente dinámico e inestable, caracterizado por rápidos avances tecnológicos, fuerte competencia y dependencia de infraestructura y servicios externos. Estos factores introducen riesgos que pueden afectar la sostenibilidad y evolución del sistema.

En este contexto, las estrategias recomendadas se orientan a fortalecer la posición financiera y operativa de la propuesta mediante contratos a largo plazo (Setup Fee + Licencias), asegurar despliegues robustos en los servidores del cliente y promover el desarrollo de alianzas estratégicas locales (Partnerships con Software Factories). Asimismo, resulta clave la mejora continua de la función de calidad agregada, con el objetivo de consolidar y proteger la ventaja competitiva frente a soluciones comerciales genéricas ofrecidas por grandes corporaciones tecnológicas.

Estudio de Mercado

1. Contextualización del Entorno y Planteamiento de la Necesidad

1.1 Identificación del problema tecnológico o de negocio

A pesar de los avances en sistemas basados en Inteligencia Artificial Generativa, uno de los principales obstáculos para su adopción efectiva en entornos organizacionales no reside en la capacidad de generar respuestas, sino en la confiabilidad, vigencia y gobernanza del conocimiento que las sustenta.

Desde una perspectiva técnica, un sistema de Generación Aumentada por Recuperación (*Retrieval-Augmented Generation, RAG*) puede conceptualizarse como un proceso en el cual, dado un conjunto de documentos D , una consulta q y un modelo generativo G , la calidad de la respuesta generada depende de la relevancia, cobertura y actualidad del subconjunto de información recuperado $D_q \subseteq D$. En este sentido, la precisión del sistema no está determinada únicamente por el modelo generativo, sino por la calidad y vigencia del conocimiento disponible.

La literatura académica ha evidenciado que los modelos de lenguaje de gran escala (LLMs) presentan limitaciones estructurales asociadas a la generación de contenido factualmente incorrecto, aun cuando este resulte lingüísticamente coherente, fenómeno conocido como hallucination (Bender et al., 2021; Ji et al., 2023). En respuesta a esta problemática, los sistemas RAG han sido propuestos como un enfoque que permite fundamentar las respuestas en fuentes externas, reduciendo la dependencia del conocimiento paramétrico del modelo (Lewis et al., 2020). No obstante, investigaciones recientes indican que la incorporación de mecanismos de recuperación no resuelve completamente los problemas asociados a la confiabilidad del sistema. En particular, los sistemas RAG continúan siendo altamente dependientes de la calidad, cobertura y vigencia de la base de conocimiento, lo que introduce nuevas fuentes de error vinculadas a la recuperación incompleta, la desactualización de los datos y la falta de alineación con el contexto actual del dominio (Gao et al., 2023).

En este contexto, es necesario distinguir tres fenómenos relacionados pero conceptualmente distintos. El *data drift* refiere a cambios en la distribución de los datos subyacentes, mientras que el *query drift* se vincula con variaciones en los patrones de consulta de los usuarios. Sin embargo, en sistemas RAG emerge un fenómeno adicional, denominado degradación del conocimiento (*knowledge drift*), que puede definirse como la pérdida progresiva de validez factual del conocimiento almacenado respecto del estado actual del dominio, aun cuando la estructura del sistema permanezca inalterada.

Este fenómeno presenta una característica crítica: el sistema mantiene coherencia lingüística mientras pierde precisión factual, dificultando la detección de errores. A diferencia de otros sistemas, donde las fallas se manifiestan explícitamente, en modelos generativos los errores pueden permanecer ocultos, incrementando el riesgo operativo.

La relevancia de esta problemática ha sido evidenciada en contextos reales. Un caso paradigmático es el proceso judicial Mata v. Avianca Airlines (2023), en el cual el uso de herramientas basadas en modelos de lenguaje derivó en la presentación de jurisprudencia inexistente

ante un tribunal. Este episodio no constituye un hecho aislado, sino una manifestación concreta de las limitaciones estructurales asociadas a la falta de control sobre la calidad y vigencia del conocimiento en sistemas generativos.

Desde una perspectiva organizacional, esta problemática se traduce en tres aspectos principales: incremento del riesgo en la toma de decisiones, dificultad en la detección de fallas y aumento de los costos operativos asociados a la actualización manual del conocimiento.

En consecuencia, se identifica una brecha en el estado actual de la tecnología: si bien existen herramientas de recuperación de información y frameworks de evaluación, son limitadas las soluciones que integran evaluación continua, detección de degradación y actualización controlada del conocimiento.

Por lo tanto, el problema central no radica únicamente en la generación o recuperación de información, sino en la ausencia de arquitecturas capaces de gestionar de manera integral el ciclo de vida del conocimiento en sistemas basados en modelos de lenguaje, lo que limita su adopción en entornos donde la confiabilidad y trazabilidad son requisitos fundamentales.

1.2 Descripción del sector y mercado piloto (nicho de adopción inicial)

La problemática anteriormente descrita adquiere una relevancia particular en entornos donde la información constituye un activo crítico y su correcta interpretación resulta determinante para la toma de decisiones. En este sentido, el ámbito gubernamental y el sector de tecnología legal (LegalTech) se posicionan como escenarios especialmente exigentes para la adopción de sistemas basados en Inteligencia Artificial Generativa.

Estos entornos se caracterizan por una alta dependencia de flujos documentales intensivos, donde normativas, jurisprudencia y documentación administrativa deben ser procesadas con elevados niveles de precisión y trazabilidad. A diferencia de otros dominios, los errores en la información pueden derivar en consecuencias legales, administrativas y económicas significativas.

La elección de este sector como nicho de adopción inicial se fundamenta en la convergencia de múltiples factores críticos. En primer lugar, el volumen y la complejidad documental, dado que las organizaciones gestionan extensos repositorios de información heterogénea cuya magnitud dificulta su procesamiento mediante enfoques tradicionales.

En segundo lugar, el dinamismo normativo, ya que la información se encuentra en constante evolución como resultado de cambios legislativos, regulatorios o jurisprudenciales. Esta característica incrementa la probabilidad de obsolescencia del conocimiento, exacerbando el fenómeno de *knowledge drift* y afectando directamente la confiabilidad del sistema.

En tercer lugar, la criticidad del dominio implica que los errores en la información no solo afectan la calidad del servicio, sino que pueden comprometer la validez de decisiones institucionales. En este sentido, la confiabilidad del sistema se convierte en un requisito estructural, superando la mera optimización operativa.

Finalmente, la soberanía de los datos y el cumplimiento normativo constituyen restricciones determinantes para la adopción tecnológica. La naturaleza sensible de la información gestionada limita el uso de infraestructuras externas, favoreciendo arquitecturas que permitan el control directo sobre los datos y su procesamiento, en línea con marcos regulatorios como la Ley N.º 25.326 de Protección de Datos Personales.

En este escenario, el sector legal y gubernamental no solo representa un ámbito de aplicación relevante, sino un entorno de validación particularmente exigente, en el cual las limitaciones de los enfoques actuales se manifiestan con mayor claridad. En consecuencia, se configura como el contexto adecuado para analizar y validar soluciones orientadas a la gestión integral del conocimiento en sistemas basados en modelos de lenguaje, especialmente aquellas que incorporen mecanismos de evaluación continua, detección de degradación y actualización controlada.

2. Análisis de la Demanda (Usuarios y Beneficiarios)

2.1 Perfil del usuario objetivo

El ecosistema de demanda de la arquitectura LLMOps propuesta se enmarca en un modelo de adopción organizacional (*B2B/B2G*), orientado a sectores donde la gestión del conocimiento reviste un carácter crítico. En estos contextos, la adopción de soluciones basadas en inteligencia artificial no está impulsada únicamente por la innovación tecnológica, sino principalmente por la necesidad de mitigar riesgos operativos asociados al uso de información potencialmente desactualizada o inconsistente.

En este marco, se identifican dos perfiles de usuarios diferenciados, cuyas necesidades reflejan tanto el consumo como la gestión del conocimiento en sistemas RAG en entornos productivos.

En primer lugar, los *usuarios operadores (tomadores de decisiones)*, conformados por profesionales como jueces, abogados, auditores de cumplimiento normativo y funcionarios públicos, cuya actividad depende de la consulta y análisis de grandes volúmenes de información normativa y documental. Desde la perspectiva de la demanda, estos usuarios enfrentan dos problemáticas principales. Por un lado, la creciente complejidad y volumen de la información dificulta su procesamiento manual en tiempos operativos adecuados. Por otro lado, y de manera más crítica, la posible degradación del conocimiento (*knowledge drift*) introduce un riesgo significativo, ya que el sistema puede proveer respuestas coherentes basadas en información obsoleta, afectando directamente la validez de las decisiones.

En este contexto, el valor percibido de la solución no se limita a la eficiencia en la recuperación de información, sino que se extiende a la necesidad de garantizar su confiabilidad, trazabilidad y vigencia. La capacidad de acceder a información respaldada por fuentes verificables y actualizadas se convierte así en un requisito fundamental para mitigar riesgos en la toma de decisiones.

En segundo lugar, se identifican los *usuarios administradores y auditores de conocimiento*, que incluyen ingenieros de datos, responsables de tecnología y especialistas en inteligencia artificial encargados de la implementación y mantenimiento de estos sistemas. En la práctica, estos perfiles enfrentan limitaciones asociadas a la falta de visibilidad sobre el comportamiento de los sistemas RAG en producción. En particular, la detección temprana de fenómenos como el *knowledge drift* resulta compleja, dado que los errores no se manifiestan de forma explícita.

Asimismo, los procesos de actualización del conocimiento suelen depender de intervenciones manuales o semi-automatizadas, lo que incrementa la carga operativa y reduce la capacidad de adaptación del sistema frente a cambios en el dominio. Esta situación evidencia una necesidad no cubierta en términos de herramientas que permitan monitorear, evaluar y mantener la calidad del conocimiento de manera continua.

Frente a estas limitaciones, la propuesta de valor de la arquitectura LLMOps se centra en la incorporación de capacidades de observabilidad orientadas a la calidad semántica, junto con mecanismos de detección de degradación y actualización controlada del conocimiento. Estas funcionalidades permiten no solo mejorar la eficiencia operativa, sino también fortalecer la gobernanza del sistema, manteniendo la supervisión humana en los procesos críticos.

En conjunto, la diferenciación de perfiles permite evidenciar que la demanda no se limita al uso del sistema como herramienta de consulta, sino que abarca la necesidad de gestionar, supervisar y garantizar la calidad del conocimiento en sistemas RAG en producción.

2.2 Validación de la necesidad y viabilidad de la demanda

La necesidad de la arquitectura propuesta se sustenta en la convergencia entre la creciente adopción de modelos de lenguaje en entornos organizacionales, las limitaciones evidenciadas en su uso en producción y las brechas estructurales presentes en la oferta tecnológica actual.

Diversos estudios recientes evidencian un crecimiento sostenido en la incorporación de Inteligencia Artificial Generativa en sectores intensivos en gestión documental, como el ámbito legal y gubernamental (*Zhao et al., 2023*). Estas tecnologías son utilizadas para optimizar procesos de búsqueda de información, análisis documental y asistencia en la toma de decisiones, lo que refleja una demanda concreta por herramientas que mejoren el acceso y la explotación del conocimiento organizacional.

Sin embargo, las investigaciones han demostrado que las limitaciones de estos sistemas afectan directamente su viabilidad en entornos productivos. En particular, la fuerte dependencia de la calidad, cobertura y vigencia del conocimiento, junto con la ausencia de mecanismos sistemáticos de mantenimiento, genera escenarios en los cuales la confiabilidad de las respuestas no puede ser garantizada de manera sostenida.

En este contexto, el fenómeno de degradación del conocimiento (*knowledge drift*) se configura como un problema estructural, afectando la validez de las respuestas generadas a lo largo del tiempo. Este fenómeno no solo compromete la precisión de la información, sino que introduce riesgos operativos y limita la adopción efectiva de estos sistemas en dominios donde la confiabilidad es un requisito crítico.

El análisis del ecosistema tecnológico actual refuerza esta situación. La implementación de sistemas RAG en entornos productivos se basa típicamente en arquitecturas compuestas por múltiples herramientas especializadas, distribuidas en distintas capas funcionales. Por ejemplo, soluciones de procesamiento documental como Docling o Unstructured permiten estructurar información compleja; modelos de embeddings como BGE-M3 o E5, desplegados mediante infraestructuras como HuggingFace TEI, posibilitan la representación semántica del conocimiento; mientras que bases vectoriales como Qdrant, Weaviate o Milvus gestionan su almacenamiento y recuperación.

No obstante, estas capas operan de manera desacoplada y carecen de mecanismos nativos para gestionar la vigencia del conocimiento. Las bases vectoriales, por ejemplo, permiten búsquedas

eficientes, pero no incorporan capacidades para invalidar o actualizar automáticamente información obsoleta, dependiendo de procesos externos de reindexación.

En el plano de la evaluación, frameworks open source como Ragas, TruLens o DeepEval han avanzado significativamente en la medición de la calidad de sistemas RAG mediante métricas como fidelidad, relevancia y precisión del contexto. Sin embargo, estas herramientas presentan una limitación estructural: su alcance se restringe al diagnóstico, sin integrar mecanismos de acción que permitan remediar automáticamente las degradaciones detectadas.

De manera complementaria, plataformas LLMOps bajo el modelo SaaS, como LangSmith, Arize Phoenix, Braintrust o Weights & Biases, ofrecen capacidades avanzadas de observabilidad, incluyendo trazabilidad de ejecuciones, monitoreo de desempeño y detección de anomalías. A pesar de su sofisticación, estas soluciones operan bajo un paradigma de tipo open-loop, en el cual la detección de problemas no se encuentra integrada con procesos automáticos de actualización del conocimiento, requiriendo intervención manual para su resolución.

Adicionalmente, su dependencia de infraestructuras externas introduce restricciones en términos de privacidad, confidencialidad y cumplimiento normativo, particularmente relevantes en sectores como el legal y gubernamental. Esta situación refuerza la necesidad de arquitecturas que puedan operar en entornos controlados, como despliegues *on-premise* o en nubes privadas.

En consecuencia, se identifica una demanda no completamente satisfecha: las organizaciones requieren no solo herramientas para la recuperación, evaluación y monitoreo de información, sino soluciones integrales que permitan gestionar de manera continua la calidad, vigencia y confiabilidad del conocimiento. Esta limitación evidencia que el problema no es únicamente tecnológico, sino sistémico, afectando directamente la viabilidad de adopción de sistemas RAG en entornos productivos.

En este sentido, la arquitectura LLMOps propuesta se presenta como una respuesta alineada con estas necesidades, al integrar mecanismos de evaluación continua, detección de degradación y actualización controlada del conocimiento dentro de un enfoque de ciclo cerrado (*closed-loop*), permitiendo reducir la dependencia de intervenciones manuales y mejorar la confiabilidad operativa del sistema en contextos críticos.

3. Estado del Arte y Análisis de la Competencia (Oferta)

3.1 Tecnologías y soluciones actuales

En respuesta a la demanda identificada en la sección anterior, el estado actual de la oferta tecnológica en sistemas basados en Inteligencia Artificial Generativa se estructura en torno a un ecosistema heterogéneo de herramientas orientadas a la construcción y operación de arquitecturas de Generación Aumentada por Recuperación (RAG).

En entornos productivos, estos sistemas se implementan mediante la integración de múltiples componentes distribuidos en distintas capas del ciclo de vida del conocimiento. En particular, soluciones como Docling o Unstructured permiten el procesamiento y estructuración de documentos complejos, preservando información relevante como jerarquías y tablas; modelos de embeddings como BGE-M3 o E5, optimizados para tareas de recuperación semántica multilingüe, son desplegados mediante infraestructuras eficientes como HuggingFace TEI; mientras que bases de datos vectoriales como Qdrant, Weaviate o Milvus permiten la indexación y recuperación de información mediante técnicas de similitud semántica y búsqueda híbrida.

Si bien estas tecnologías representan el estado del arte en cada una de sus respectivas funciones, su adopción en conjunto da lugar a arquitecturas compuestas por componentes altamente especializados pero funcionalmente desacoplados. Esta fragmentación no es únicamente tecnológica, sino arquitectónica, afectando la capacidad de los sistemas para gestionar de manera autónoma y continua la calidad y vigencia del conocimiento en entornos dinámicos.

A partir del análisis del estado del arte, es posible identificar tres enfoques predominantes en la gestión de estos sistemas: (i) el mantenimiento reactivo tradicional, (ii) los frameworks de evaluación open source y (iii) las plataformas comerciales de observabilidad bajo el modelo SaaS.

3.1.1 Enfoque tradicional y mantenimiento ad hoc

En las etapas iniciales de adopción, la gestión de sistemas basados en LLMs suele apoyarse en métricas operativas convencionales, tales como latencia, disponibilidad o consumo de recursos. En este enfoque, la actualización del conocimiento se realiza mediante procesos periódicos de reindexación, generalmente definidos de manera estática y desacoplados del desempeño real del sistema.

Este paradigma presenta limitaciones significativas, ya que no permite evaluar la calidad semántica ni la veracidad de las respuestas generadas. Métricas tradicionales del procesamiento de lenguaje natural, como BLEU o ROUGE, han demostrado ser insuficientes para tareas generativas complejas, dado que no capturan adecuadamente la equivalencia semántica ni penalizan la generación de información incorrecta (Bender et al., 2021).

Como consecuencia, este enfoque conduce a esquemas de mantenimiento reactivo, en los cuales la actualización del conocimiento depende de intervenciones manuales o programaciones periódicas, sin mecanismos que permitan detectar automáticamente la degradación del desempeño. Esta limitación resulta particularmente crítica en dominios donde la información se encuentra en constante evolución.

3.1.2 Frameworks de evaluación open source

Con el objetivo de superar las limitaciones del enfoque tradicional, han surgido frameworks de código abierto orientados a la evaluación de sistemas RAG, entre los que se destacan herramientas como Ragas , TruLens y DeepEval.

Estas soluciones han contribuido a estandarizar la medición del desempeño mediante métricas más representativas, tales como la fidelidad (*faithfulness*), la relevancia de la respuesta y la precisión del contexto recuperado. Asimismo, han consolidado el paradigma LLM-as-a-judge, en el cual modelos de lenguaje son utilizados para evaluar de manera automatizada las salidas generadas por otros sistemas (Zheng et al., 2023).

No obstante, estas herramientas presentan una limitación estructural relevante: su alcance se restringe al diagnóstico. Si bien permiten identificar degradaciones en la calidad del sistema, no integran mecanismos nativos que permitan accionar sobre dichas detecciones, como la actualización automática del conocimiento o la remediación de errores.

En consecuencia, estos frameworks operan como sistemas de evaluación desacoplados, cuya salida requiere ser interpretada y gestionada manualmente, manteniendo una lógica de operación de tipo *open-loop*.

3.1.3 Plataformas LLMOps comerciales (SaaS)

En el ámbito comercial, el estado del arte se encuentra representado por plataformas LLMOps bajo el modelo Software as a Service (SaaS), tales como LangSmith, Arize Phoenix, Braintrust y Weights & Biases (Weave).

Estas plataformas proporcionan capacidades avanzadas de observabilidad, incluyendo trazabilidad de ejecuciones, monitoreo de métricas en tiempo real, análisis de comportamiento del sistema y detección de anomalías. Estas funcionalidades permiten a los equipos técnicos comprender el rendimiento del sistema, identificar fallas y optimizar componentes como prompts o estrategias de recuperación.

Sin embargo, estas soluciones presentan limitaciones estructurales en relación con la gestión del conocimiento. Si bien optimizan la observabilidad del sistema, no abordan de manera integral su gobernanza. En particular, operan bajo un paradigma de tipo *open-loop*, en el cual la detección de

problemas no se encuentra integrada con mecanismos automáticos de remediación, requiriendo intervención manual para su resolución.

Adicionalmente, su dependencia de infraestructuras externas introduce restricciones en términos de privacidad, confidencialidad y cumplimiento normativo. Esta característica limita su adopción en sectores regulados, donde el control sobre los datos constituye un requisito fundamental.

3.2 Evaluación comparativa (Benchmarking)

El análisis comparativo se orienta a evaluar el grado de cobertura del ciclo de vida del conocimiento en sistemas RAG, identificando no solo las capacidades presentes en cada enfoque, sino también las ausencias estructurales que limitan su adopción en entornos productivos.

En este contexto, se comparan tres enfoques: (i) la arquitectura LLMOps propuesta, (ii) plataformas comerciales SaaS y (iii) frameworks open source de evaluación. Cabe destacar que estos últimos no constituyen soluciones completas, sino componentes que pueden integrarse dentro de arquitecturas más amplias.

Tabla 3. Matriz de Benchmarking Tecnológico

Criterio de Evaluación	Arquitectura LLMOps (Propuesta)	Plataformas SaaS	Frameworks Open Source
Soberanía y despliegue	<i>Implementación on-premise o en infraestructuras dedicadas, con control total sobre los datos.</i>	<i>Predominantemente en la nube, con dependencia de proveedores externos.</i>	<i>Dependiente del entorno de integración.</i>
Evaluación y detección de drift	<i>Integración de métricas determinísticas, evaluación semántica (LLM-as-a-judge) y señales de usuario mediante función agregada (Q).</i>	<i>Capacidades avanzadas de monitoreo y análisis del desempeño.</i>	<i>Foco en métricas específicas de evaluación.</i>
Actualización del conocimiento	<i>Enfoque closed-loop con activación automática de procesos de actualización.</i>	<i>Requiere integraciones externas para automatización.</i>	<i>No incluyen mecanismos de actualización.</i>

Nivel de integración	<i>Gestión integral del ciclo de vida del conocimiento.</i>	<i>Enfoque centrado en la observabilidad.</i>	<i>Componentes modulares aislados.</i>
Control y gobernanza	<i>Integración de human-in-the-loop para validación.</i>	<i>Control limitado sobre automatización.</i>	<i>Requiere implementación manual.</i>
Modelo de costos	<i>Costos predecibles en entornos controlados.</i>	<i>Pago por uso.</i>	<i>Sin licencia, con costos de integración.</i>

Fuente: Elaboración propia basada en el análisis de plataformas LLMOps y frameworks de evaluación RAG.

A partir de esta evaluación, se observa que las soluciones actuales presentan fortalezas específicas en distintas capas del sistema, pero carecen de integración entre ellas. De manera predominante, las herramientas disponibles abordan el problema de forma parcial, concentrándose en la evaluación o el monitoreo, sin incorporar mecanismos que permitan vincular la detección de degradación con procesos automáticos de actualización del conocimiento.

Esta limitación refleja una fragmentación estructural en la gestión del ciclo de vida del conocimiento, lo que obliga a las organizaciones a implementar soluciones ad hoc para integrar componentes heterogéneos, incrementando la complejidad operativa y el riesgo de inconsistencias.

En este contexto, la arquitectura propuesta se posiciona como un enfoque integrador, orientado a articular estas capacidades dentro de un esquema de tipo closed-loop, en el cual la evaluación del sistema actúa como disparador de procesos de actualización controlada del conocimiento.

De este modo, la propuesta no solo mejora la eficiencia técnica del sistema, sino que permite superar una limitación estructural del estado del arte, habilitando la adopción de sistemas RAG en entornos productivos donde la confiabilidad, trazabilidad y vigencia del conocimiento son requisitos indispensables.

4. Identificación de la Brecha Tecnológica y Oportunidad

4.1 Limitaciones de la oferta actual

A partir del análisis del estado del arte, se observa que las soluciones actuales en el ámbito de la Inteligencia Artificial Generativa aplicada a la gestión del conocimiento presentan desajustes estructurales frente a los requerimientos de entornos de alta criticidad. Si bien el ecosistema tecnológico ha avanzado en el desarrollo de herramientas especializadas para la evaluación, monitoreo y operación de sistemas RAG, dichas capacidades se encuentran fragmentadas y no logran conformar soluciones integrales para su operación en producción.

Una primera limitación relevante se vincula con la **soberanía de los datos**. De manera predominante, las plataformas LLMOps disponibles en el mercado operan bajo modelos de despliegue SaaS, lo que implica el procesamiento de información en infraestructuras externas. Esta característica introduce restricciones en términos de privacidad, confidencialidad y cumplimiento normativo, especialmente en sectores regulados donde el control sobre los datos constituye un requisito esencial.

En segundo lugar, se identifica una **desarticulación entre los mecanismos de evaluación y la operación del sistema**, reflejada en la prevalencia de arquitecturas de tipo *open-loop*. Si bien las herramientas actuales permiten monitorear el desempeño y detectar degradaciones en la calidad del sistema, estas capacidades no se encuentran integradas con mecanismos que permitan ejecutar acciones correctivas de manera automática. Como consecuencia, la actualización del conocimiento continúa dependiendo de procesos manuales o semi-automatizados, limitando la capacidad de adaptación del sistema frente a cambios en el dominio.

En tercer lugar, se evidencian limitaciones en la **gobernanza del conocimiento**. Algunas soluciones orientadas a la automatización carecen de mecanismos estructurados de validación, lo que puede derivar en la incorporación de información incorrecta o no verificada. En este sentido, la literatura en sistemas de inteligencia artificial destaca la importancia de integrar enfoques

human-in-the-loop para garantizar la supervisión, trazabilidad y confiabilidad en entornos productivos (Amershi et al., 2019).

En conjunto, estas limitaciones reflejan un problema estructural más profundo: la gestión del ciclo de vida del conocimiento en sistemas RAG se encuentra fragmentada entre múltiples herramientas que operan de manera desacoplada. Esta fragmentación obliga a las organizaciones a implementar soluciones ad hoc para integrar capacidades de evaluación, monitoreo y actualización, incrementando la complejidad operativa y el riesgo de inconsistencias.

En este contexto, la brecha tecnológica central puede definirse como:

“La ausencia de arquitecturas LLMOps que integren de manera unificada la evaluación del desempeño, la detección de degradación del conocimiento y su actualización controlada, dentro de entornos que garanticen simultáneamente la soberanía de los datos y mecanismos de supervisión humana.”

Esta brecha genera una disyuntiva en las organizaciones que operan en entornos críticos. Por un lado, pueden adoptar plataformas comerciales avanzadas que ofrecen capacidades de observabilidad, pero con restricciones en términos de control y privacidad. Por otro lado, pueden optar por desarrollos internos que priorizan la soberanía de los datos, pero que suelen carecer de mecanismos robustos para garantizar la calidad y actualización continua del conocimiento.

En consecuencia, la problemática identificada no radica únicamente en la disponibilidad de herramientas, sino en la falta de integración entre sus capacidades, lo que limita la gestión efectiva y confiable del conocimiento en sistemas RAG en entornos productivos.

4.2 Propuesta de valor y diferencial de la arquitectura

En respuesta a la brecha identificada, la presente tesis propone una arquitectura LLMOps orientada a la gestión integral del conocimiento en sistemas RAG, diseñada específicamente para su aplicación en entornos regulados y de alta criticidad.

A diferencia de las soluciones existentes, la propuesta no se centra en optimizar componentes aislados, sino en articular de manera coherente las distintas capacidades necesarias para gestionar el ciclo de vida del conocimiento dentro de un enfoque unificado.

En primer lugar, la arquitectura introduce un mecanismo de **remediación automatizada basado en un enfoque de ciclo cerrado (*closed-loop*)**. En este esquema, la evaluación del desempeño del sistema no se limita al diagnóstico, sino que actúa como disparador de procesos de actualización del conocimiento. De este modo, se reduce la dependencia de intervenciones manuales y se mejora la capacidad de adaptación del sistema frente a cambios en el dominio.

En segundo lugar, la propuesta incorpora el principio de ***cumplimiento normativo por diseño (compliance-by-design)***, priorizando su implementación en entornos controlados, como infraestructuras on-premise o nubes privadas. Este enfoque permite garantizar la soberanía de los datos y alinear la arquitectura con marcos regulatorios exigentes, constituyendo un factor diferencial frente a soluciones basadas exclusivamente en modelos SaaS.

En tercer lugar, se define un modelo de **evaluación híbrida**, que integra métricas determinísticas, evaluaciones semánticas mediante el paradigma *LLM-as-a-judge* y señales derivadas de la interacción con los usuarios. Esta combinación se sintetiza en una función agregada de calidad (*Q*), que permite obtener una visión integral del desempeño del sistema en producción y detectar de manera temprana posibles degradaciones.

Finalmente, la arquitectura incorpora un enfoque de *gobernanza basado en human-in-the-loop*, mediante el cual los procesos críticos de actualización del conocimiento requieren validación humana previa. Este mecanismo permite equilibrar la automatización con el control, asegurando la trazabilidad de los cambios y la confiabilidad del sistema en contextos donde la precisión de la información es fundamental.

En conjunto, estos elementos configuran una propuesta que no solo responde a las limitaciones identificadas en la oferta actual, sino que redefine el enfoque de gestión del conocimiento en sistemas RAG, avanzando desde modelos fragmentados y reactivos hacia arquitecturas integradas, adaptativas y orientadas a la confiabilidad operativa.

5. Viabilidad y Estrategia de Implementación (CONTROLAR)

5.1 Modelo de adopción o despliegue

La arquitectura propuesta se orienta a un modelo de adopción organizacional de tipo B2B/B2G, dirigido a instituciones donde la gestión del conocimiento constituye un activo crítico, tales como organismos gubernamentales, el Poder Judicial y grandes estudios jurídicos corporativos. En estos entornos, la adopción tecnológica se encuentra fuertemente condicionada por requerimientos de confidencialidad, trazabilidad y cumplimiento normativo.

A diferencia de soluciones basadas en modelos SaaS, la propuesta se estructura bajo un esquema de **licenciamiento de software con despliegue on-premise o en infraestructuras dedicadas**, lo que permite implementar el sistema directamente sobre los entornos del cliente. Este enfoque garantiza la soberanía de los datos y evita la exposición de información sensible en plataformas externas, constituyendo un factor determinante para su adopción en sectores regulados.

Desde una perspectiva económica, el modelo de implementación se basa en un esquema de doble componente. En primer lugar, un **costo inicial de implementación (Setup Fee)**, asociado a la

instalación de la arquitectura, la configuración del pipeline de ingesta y la integración con los repositorios documentales del cliente. En segundo lugar, una **licencia anual de uso**, que incluye el acceso al motor de evaluación de calidad, el soporte técnico y la evolución continua del sistema.

Este modelo permite distribuir los costos en el tiempo, diferenciando entre una inversión inicial vinculada a la puesta en marcha del sistema y costos recurrentes asociados a su operación y mantenimiento. Asimismo, al tratarse de una solución desplegada en infraestructura controlada, se evita la dependencia de esquemas de pago por uso, favoreciendo una mayor previsibilidad económica para la organización.

Adicionalmente, la arquitectura presenta un diseño modular que facilita su integración con sistemas preexistentes, tales como repositorios documentales o sistemas de gestión de expedientes electrónicos. De este modo, la solución no requiere la sustitución de infraestructuras existentes, sino que se incorpora como una capa adicional de procesamiento y orquestación del conocimiento, reduciendo el costo y la complejidad de adopción.

5.2 Viabilidad operativa y de mercado

La viabilidad operativa de la arquitectura se fundamenta en el nivel de madurez tecnológica de los sectores objetivo. En particular, tanto el ámbito gubernamental como el legal han avanzado significativamente en procesos de digitalización, disponiendo de grandes volúmenes de información estructurada y no estructurada, tales como normativa, jurisprudencia y expedientes electrónicos. Esta disponibilidad de datos constituye un insumo clave para la implementación de sistemas RAG, facilitando su adopción sin requerir transformaciones estructurales profundas.

Desde una perspectiva técnica, los costos de implementación de la arquitectura se distribuyen en tres componentes principales: *(i)* procesamiento e ingesta documental, *(ii)* generación y almacenamiento de representaciones vectoriales, y *(iii)* ejecución de modelos de lenguaje y mecanismos de evaluación. Estas capacidades pueden ser implementadas mediante tecnologías open

source ampliamente adoptadas, lo que permite reducir costos de licenciamiento y aumentar la flexibilidad del sistema.

El principal costo operativo se asocia al uso de recursos computacionales, particularmente en la generación de embeddings, la inferencia de modelos y la ejecución de procesos de evaluación continua. No obstante, al tratarse de una arquitectura desplegada en entornos controlados, estos costos pueden dimensionarse de acuerdo con la demanda específica de cada organización, optimizando la asignación de recursos y evitando la variabilidad característica de modelos externos.

Desde el punto de vista organizacional, la incorporación de mecanismos de supervisión humana (*human-in-the-loop*) constituye un factor clave para la viabilidad de adopción. En entornos donde las decisiones tienen implicancias legales o regulatorias, la automatización completa suele generar resistencia. La integración de instancias de validación por parte de expertos permite mitigar estos riesgos, posicionando al sistema como una herramienta de apoyo a la toma de decisiones, en lugar de un sustituto de la misma.

En términos de mercado, el modelo propuesto presenta ventajas competitivas frente a soluciones estandarizadas, al ofrecer una arquitectura adaptable, auditable y alineada con requerimientos específicos de cada organización. La combinación de despliegue controlado, modelo de licenciamiento y capacidades de gobernanza del conocimiento permite no solo resolver una problemática técnica compleja, sino también construir una propuesta de valor sostenible desde el punto de vista económico.

En conjunto, la arquitectura propuesta se presenta como una solución viable tanto desde la perspectiva operativa como comercial, al equilibrar costos de implementación, control sobre la infraestructura y adecuación a entornos regulados, favoreciendo su adopción en escenarios donde la confiabilidad del conocimiento constituye un requisito crítico.

Nota: El presente análisis aborda la viabilidad desde una perspectiva estratégica y de adopción. Los aspectos técnicos específicos y el análisis económico detallado de la implementación serán desarrollados en etapas posteriores del trabajo.

6. Conclusiones del Estudio de Mercado

6.1 Síntesis de hallazgos

El análisis desarrollado permite concluir que la adopción de sistemas basados en Inteligencia Artificial Generativa, particularmente arquitecturas RAG, ha generado una demanda concreta por soluciones que garanticen la calidad, vigencia y confiabilidad del conocimiento en entornos productivos. Esta necesidad resulta especialmente crítica en sectores regulados, donde la precisión de la información impacta directamente en la toma de decisiones.

El estudio de la oferta tecnológica evidenció que las soluciones actuales se encuentran fragmentadas, concentrándose en capacidades específicas como la evaluación o el monitoreo, pero sin integrar mecanismos que permitan gestionar de forma continua la actualización del conocimiento. Como resultado, los sistemas operan bajo esquemas predominantemente open-loop, limitando su capacidad de adaptación y reduciendo su confiabilidad en el tiempo.

A partir de este escenario, se identificó una brecha tecnológica central: la ausencia de arquitecturas que integren de manera unificada la evaluación del desempeño, la detección de degradación y la actualización controlada del conocimiento, bajo condiciones que garanticen la soberanía de los datos y la trazabilidad del sistema.

En respuesta a esta brecha, la arquitectura LLMOps propuesta introduce un enfoque closed-loop, orientado a gestionar el ciclo de vida del conocimiento de forma integral, incorporando además mecanismos de supervisión humana. Este enfoque permite mejorar la confiabilidad operativa del sistema y alinearlos con los requerimientos de entornos organizacionales de alta criticidad.

En consecuencia, el estudio de mercado permite afirmar que el desarrollo de este tipo de arquitecturas no constituye únicamente una mejora tecnológica, sino un habilitador necesario para la adopción efectiva de sistemas RAG en escenarios reales.

Ingeniería de Requerimientos

Introducción a la Ingeniería de Requerimientos

La Ingeniería de Requerimientos constituye una disciplina fundamental dentro del proceso de desarrollo de sistemas de software, orientada a la identificación, análisis, especificación y validación de las necesidades que debe satisfacer una solución tecnológica. Su objetivo principal es reducir la ambigüedad, alinear las expectativas de los distintos actores involucrados y establecer una base sólida para el diseño e implementación del sistema.

En el contexto del presente trabajo, esta sección tiene como propósito formalizar, en términos técnicos y estructurados, las necesidades previamente identificadas en el estudio de mercado, traduciéndolas en un conjunto coherente de requerimientos para la arquitectura LLMOps propuesta. De este modo, se definen las funcionalidades, restricciones y condiciones de operación que el sistema deberá cumplir para garantizar una gestión confiable, trazable y actualizada del conocimiento en sistemas de Generación Aumentada por Recuperación (RAG).

A diferencia del análisis previo, centrado en la comprensión del problema y del entorno de adopción, la Ingeniería de Requerimientos se enfoca en la especificación concreta del sistema, estableciendo criterios verificables que guiarán su diseño, desarrollo y validación. En este sentido, se priorizan dimensiones clave como la calidad de las respuestas, la detección de degradación del conocimiento (drift), la observabilidad del sistema y la gobernanza del ciclo de vida del conocimiento, elementos esenciales para su aplicación en entornos de alta criticidad.

Asimismo, la definición de los requerimientos se encuentra condicionada por el marco normativo vigente, particularmente por la Ley N.º 25.326 de Protección de Datos Personales. En

consecuencia, la arquitectura deberá contemplar mecanismos que garanticen la seguridad, confidencialidad, auditabilidad y control de la información, siendo compatible con esquemas de despliegue en infraestructuras controladas (on-premise o nubes privadas) que aseguren la soberanía de los datos.

En conjunto, esta sección establece las bases formales sobre las cuales se estructurará la solución propuesta, permitiendo vincular de manera directa las necesidades del dominio con las decisiones de diseño arquitectónico, en el marco de un enfoque LLMOps orientado a la supervisión continua y mejora adaptativa de sistemas RAG.

Identificación de Stakeholders

La identificación de stakeholders permite reconocer a los actores que interactúan con el sistema y comprender sus necesidades, expectativas y restricciones, constituyendo un insumo clave para la definición de los requerimientos (Sommerville, 2011). En el contexto de la arquitectura LLMOps propuesta, el sistema se configura como un sistema sociotécnico complejo, en el cual convergen múltiples perfiles con distintos niveles de interacción, responsabilidad e influencia. En consecuencia, la correcta identificación y caracterización de los stakeholders resulta crítica para asegurar la alineación entre los objetivos del sistema, su diseño arquitectónico y las condiciones de operación en entornos de alta criticidad.

A continuación, se describen los principales stakeholders identificados:

Usuarios Operadores (Usuarios finales)

Este grupo está conformado por profesionales que interactúan con la capa conversacional del sistema RAG, tales como abogados, jueces, funcionarios públicos y analistas de información. Su principal objetivo es acceder de manera eficiente a información relevante, obteniendo respuestas precisas, actualizadas y fundamentadas a partir de grandes volúmenes de documentación.

Desde su perspectiva, el sistema debe garantizar altos niveles de confiabilidad, claridad y trazabilidad, permitiendo no solo interpretar las respuestas generadas, sino también comprender las fuentes que las sustentan. En este sentido, la calidad percibida por estos usuarios se convierte en un factor crítico para la adopción del sistema.

Asimismo, su interacción constituye una fuente indirecta de retroalimentación, ya que sus consultas, patrones de uso y posibles correcciones pueden ser utilizados como señales para la evaluación continua del sistema dentro del enfoque LLMOps.

Administradores del Sistema (LLMOps / IT)

Este grupo está conformado por ingenieros de datos, especialistas en inteligencia artificial y personal técnico responsable de la operación del sistema. Su interacción se centra en las capas de monitoreo, evaluación y mantenimiento de la arquitectura.

Entre sus principales responsabilidades se encuentran la supervisión del desempeño del sistema, la detección de drift y la orquestación de procesos de actualización de la base de conocimiento. En este contexto, requieren herramientas avanzadas de observabilidad, métricas interpretables y mecanismos que faciliten la toma de decisiones operativas.

Dentro del enfoque LLMOps, estos stakeholders desempeñan un rol central en la implementación del ciclo de mejora continua (closed-loop), actuando como responsables de traducir los resultados de la evaluación en acciones concretas sobre el sistema.

Audidores y responsables de cumplimiento (Compliance)

En entornos regulados, se identifica un grupo de stakeholders vinculado al control, la supervisión y la validación del sistema. Este grupo incluye auditores, responsables de cumplimiento normativo y autoridades institucionales encargadas de garantizar que el sistema opere conforme a las regulaciones vigentes.

Estos actores demandan capacidades de trazabilidad, transparencia y explicabilidad, que permitan auditar tanto las respuestas generadas como los procesos de actualización del conocimiento. Su rol resulta especialmente relevante en la validación de cambios críticos dentro del sistema, en línea con enfoques de supervisión human-in-the-loop, considerados fundamentales para el desarrollo de sistemas de inteligencia artificial confiables (Amershi et al., 2019).

En este sentido, su influencia se traduce en la imposición de restricciones y requisitos no funcionales asociados a la seguridad, auditabilidad y cumplimiento normativo.

Sistemas externos e infraestructura de datos

Además de los actores humanos, es necesario considerar como stakeholders a los sistemas externos que interactúan con la arquitectura propuesta. Entre ellos se incluyen repositorios documentales, sistemas de gestión de expedientes, bases de datos normativas y pipelines de procesamiento de datos (ETL).

Estos sistemas constituyen la fuente primaria de información sobre la cual opera el modelo RAG, y su correcta integración resulta fundamental para garantizar la actualización y consistencia del conocimiento. En este sentido, su inclusión dentro del análisis de stakeholders permite contemplar dependencias técnicas que impactan directamente en la definición de los requerimientos.

Síntesis del análisis de stakeholders

El análisis realizado permite evidenciar que la arquitectura propuesta debe responder a un conjunto heterogéneo de necesidades, que abarcan tanto la obtención de información confiable por parte de los usuarios finales, como la gestión operativa, la supervisión técnica y el cumplimiento normativo del sistema.

En términos de influencia e interés, se observa que los usuarios operadores presentan un alto nivel de interés pero una influencia indirecta sobre la evolución del sistema, mientras que los

administradores LLMOps concentran tanto un alto nivel de interés como una influencia directa sobre su funcionamiento. Por su parte, los auditores y responsables de cumplimiento ejercen una influencia crítica en la definición de restricciones y condiciones de operación, especialmente en entornos regulados.

Esta diversidad de actores refuerza la necesidad de adoptar un enfoque integral en la definición de requerimientos, que no se limite a funcionalidades específicas, sino que incorpore aspectos vinculados a la gobernanza del conocimiento, la trazabilidad de las decisiones y la confiabilidad del sistema en su conjunto.

En este contexto, la identificación de stakeholders no solo permite comprender el ecosistema de uso del sistema, sino también establecer criterios para la priorización de requerimientos, asegurando que las decisiones de diseño respondan de manera equilibrada a las necesidades operativas, técnicas y regulatorias del dominio.

Escenarios de Uso y Modelado de Casos de Uso

Con el objetivo de garantizar la consistencia metodológica y la trazabilidad hacia los requerimientos del sistema, las interacciones identificadas se estructuran mediante escenarios de uso y su posterior formalización en casos de uso. Este enfoque permite describir de manera precisa el comportamiento del sistema, definiendo actores involucrados, flujos operativos, condiciones de ejecución y resultados observables.

En el contexto de la arquitectura LLMOps propuesta, los escenarios de uso reflejan un modelo de operación continuo (closed-loop), en el cual la generación de respuestas, su evaluación, la detección de degradación del conocimiento y su posterior actualización se integran en un ciclo controlado, auditable y orientado a la mejora continua.

A diferencia de sistemas tradicionales, donde los casos de uso suelen centrarse exclusivamente en la interacción usuario-sistema, en esta propuesta se incorporan procesos internos

automatizados y supervisados que forman parte del ciclo de vida del conocimiento. En consecuencia, los casos de uso incluyen tanto interacciones directas con usuarios como procesos internos del sistema y actividades de validación humana.

A continuación, se presentan los principales casos de uso identificados, organizados en función de las etapas del ciclo operativo de la arquitectura.

CU-01: Consulta de información mediante arquitectura RAG

Actor principal: *Usuario Operador*

Este caso de uso describe el flujo principal de interacción del sistema. El usuario realiza una consulta en lenguaje natural a través de la interfaz conversacional, con el objetivo de obtener información relevante a partir de una base documental.

El sistema procesa la consulta mediante mecanismos de recuperación de información y generación de respuestas, devolviendo un resultado estructurado acompañado de referencias a las fuentes utilizadas.

La calidad de la respuesta, en términos de precisión, actualidad y fundamentación, constituye un factor crítico para la aceptación del sistema, especialmente en entornos donde la confiabilidad de la información es determinante para la toma de decisiones.

CU-02: Evaluación de la calidad de las respuestas

Actor principal: *Sistema*

Actor secundario: *Administrador LLMOps*

En este caso de uso, el sistema ejecuta procesos de evaluación sobre las respuestas generadas, utilizando un enfoque híbrido que combina métricas determinísticas, evaluación semántica mediante modelos de lenguaje y señales derivadas del comportamiento del usuario.

El resultado de este proceso es un puntaje agregado de calidad, que permite medir el desempeño del sistema e identificar posibles desviaciones. Esta evaluación se realiza de manera continua durante la operación del sistema, sin requerir interacción directa del usuario final.

Este caso de uso constituye un componente central de la arquitectura LLMOps, ya que habilita la medición de la calidad semántica de las respuestas, aspecto que no puede ser capturado mediante métricas tradicionales de software.

CU-03: Detección de degradación del conocimiento (drift semántico)

Actor principal: *Sistema*

A partir de los resultados de evaluación, el sistema analiza la evolución temporal de las métricas de calidad con el objetivo de identificar patrones de degradación del conocimiento.

Cuando se detectan desviaciones significativas respecto a umbrales predefinidos, el sistema genera alertas que indican la posible presencia de drift semántico, ya sea como consecuencia de cambios en el corpus documental (data drift) o en los patrones de consulta (query drift).

Este caso de uso permite anticipar fallas en el sistema antes de que impacten en la experiencia del usuario, constituyendo un mecanismo clave para la adaptabilidad y sostenibilidad del sistema en entornos dinámicos.

CU-04: Actualización del conocimiento mediante procesos ETL

Actor principal: *Administrador LLMOps*

Actor secundario: *Sistema*

Ante la detección de degradación del conocimiento, se activa un proceso de actualización que implica la incorporación de nueva información en la base de conocimiento. Este proceso se implementa mediante pipelines de extracción, transformación y carga (ETL), que permiten integrar

documentos actualizados, procesarlos y reconstruir la base de conocimiento vectorial. La ejecución de este proceso puede ser automática o iniciada manualmente por los administradores del sistema, dependiendo de las políticas de operación definidas.

Este caso de uso resulta esencial para mantener la vigencia del conocimiento y garantizar la capacidad de adaptación del sistema frente a cambios en el dominio.

CU-05: Validación humana del conocimiento (Human-in-the-Loop)

Actor principal: *Auditor / Responsable de Cumplimiento*

Actor secundario: *Administrador LLMOps*

Previo a la actualización efectiva del sistema en producción, los cambios propuestos son sometidos a un proceso de validación por parte de actores humanos. Este proceso permite verificar la calidad de los documentos incorporados, evaluar la consistencia del conocimiento y detectar posibles errores antes de su despliegue. Solo tras esta validación se procede a la actualización definitiva de la base de conocimiento.

La incorporación de este mecanismo responde a la necesidad de garantizar la confiabilidad, trazabilidad y cumplimiento normativo del sistema, especialmente en entornos donde la precisión de la información resulta crítica.

Síntesis de los escenarios de uso

Los casos de uso descritos evidencian que la arquitectura propuesta no se limita a la generación de respuestas, sino que implementa un ciclo completo de gestión del conocimiento. Este ciclo integra procesos de consulta, evaluación, detección de degradación, actualización y validación, configurando un modelo de operación de tipo closed-loop.

Este enfoque permite no solo mejorar la calidad de las respuestas generadas, sino también garantizar la evolución controlada del conocimiento, alineándose con los principios de LLMOps y con los requerimientos de confiabilidad y gobernanza propios de entornos de alta criticidad.

En conjunto, los casos de uso constituyen la base para la definición de los requerimientos funcionales y no funcionales del sistema, así como para el diseño de la arquitectura que los soporta.

Requerimientos Funcionales

Los requerimientos funcionales definen las capacidades que debe implementar el sistema para cumplir con los objetivos establecidos. En el marco de la arquitectura LLMOps propuesta, estos requerimientos se organizan según los módulos que componen el ciclo de gestión del conocimiento, asegurando coherencia con los casos de uso y con el diseño arquitectónico.

Con el fin de facilitar su comprensión y trazabilidad, los requerimientos se agrupan en los siguientes módulos funcionales:

- **Módulo de Consulta y Generación (RAG):** encargado de procesar las consultas de los usuarios, recuperar información relevante y generar respuestas fundamentadas.
- **Módulo de Evaluación de Calidad:** responsable de medir la calidad de las respuestas generadas mediante métricas cuantitativas y evaluación semántica.
- **Módulo de Detección de Drift:** orientado a identificar degradaciones en el desempeño del sistema a lo largo del tiempo.
- **Módulo de Ingesta y Actualización de Conocimiento:** encargado de incorporar, procesar y preparar nueva información para su utilización dentro del sistema.
- **Módulo de Validación Humana:** destinado a controlar y validar los cambios en la base de conocimiento antes de su despliegue.

- **Módulo de Observabilidad y Monitoreo:** enfocado en la supervisión del comportamiento del sistema y el seguimiento de sus métricas operativas.

A continuación, se presentan los requerimientos funcionales correspondientes a cada módulo.

Módulo de Consulta y Generación (RAG)

Este módulo gestiona la interacción con el usuario, la recuperación de información y la generación de respuestas.

1. **[RF-01] Procesamiento de consultas en lenguaje natural:** El sistema deberá recibir consultas en lenguaje natural y transformarlas en representaciones vectoriales mediante un modelo de embeddings.
2. **[RF-02] Recuperación de contexto relevante:** El sistema deberá recuperar los fragmentos documentales más relevantes mediante búsqueda semántica sobre la base vectorial.
3. **[RF-03] Generación de respuesta fundamentada:** El sistema deberá generar una respuesta en lenguaje natural basada en el contexto recuperado.
4. **[RF-04] Inclusión de referencias documentales:** El sistema deberá incluir en la respuesta referencias explícitas a las fuentes utilizadas.

Módulo de Evaluación de Calidad

Este módulo permite medir la calidad de las respuestas generadas.

1. **[RF-05] Captura de retroalimentación del usuario:** El sistema deberá registrar las interacciones del usuario como señales de evaluación.
2. **[RF-06] Cálculo de métricas de recuperación:** El sistema deberá calcular métricas basadas en embeddings para evaluar la relevancia del contexto.

3. **[RF-07] Evaluación semántica de respuestas:** El sistema deberá evaluar la calidad de la respuesta mediante un modelo de lenguaje evaluador.
4. **[RF-08] Cálculo del puntaje agregado de calidad (Q):** El sistema deberá integrar las métricas en un indicador unificado de calidad.

Módulo de Detección de Drift

Este módulo permite identificar degradaciones en el desempeño del sistema.

1. **[RF-09] Registro histórico de métricas:** El sistema deberá almacenar los puntajes de calidad en estructuras de series temporales.
2. **[RF-10] Detección de degradación del desempeño:** El sistema deberá identificar desviaciones significativas en la calidad respecto a umbrales definidos.
3. **[RF-11] Clasificación del tipo de drift:** El sistema deberá distinguir entre *data drift* y *query drift*.
4. **[RF-12] Generación de alertas de degradación:** El sistema deberá notificar eventos de degradación a los administradores.

Módulo de Ingesta y Actualización de Conocimiento

Este módulo gestiona la incorporación de nueva información.

1. **[RF-13] Extracción de información desde fuentes externas:** El sistema deberá obtener documentos desde repositorios definidos.
2. **[RF-14] Procesamiento y normalización de documentos:** El sistema deberá limpiar y estructurar los documentos.

3. **[RF-15] Fragmentación del contenido (chunking):** El sistema deberá dividir los documentos en unidades coherentes.
4. **[RF-16] Vectorización y almacenamiento en entorno de staging:** El sistema deberá generar embeddings e incorporar el conocimiento en un entorno de validación.

Módulo de Validación Humana

Este módulo introduce control previo al despliegue.

1. **[RF-17] Visualización de cambios en el conocimiento:** El sistema deberá presentar las diferencias entre versiones del conocimiento.
2. **[RF-18] Registro de decisiones de validación:** El sistema deberá requerir aprobación explícita para actualizar la base de conocimiento.
3. **[RF-19] Actualización controlada del entorno productivo:** El sistema deberá actualizar la base de conocimiento tras validación.
4. **[RF-20] Registro de auditoría:** El sistema deberá mantener un historial de eventos de actualización y validación.

Módulo de Observabilidad y Monitoreo

Este módulo permite supervisar el comportamiento del sistema.

1. **[RF-21] Visualización de métricas de desempeño:** El sistema deberá presentar indicadores de calidad en un panel de control.
2. **[RF-22] Monitoreo de procesos de actualización:** El sistema deberá mostrar el estado de los pipelines de procesamiento.

3. **[RF-23] Generación de reportes de auditoría:** El sistema deberá permitir la exportación de información para análisis externo.

Requerimientos No Funcionales

Los requerimientos no funcionales establecen las restricciones y atributos de calidad bajo los cuales debe operar el sistema. En el contexto de la arquitectura LLMOps propuesta, estos requerimientos resultan fundamentales para garantizar su funcionamiento en entornos críticos, priorizando la seguridad de la información, la trazabilidad del conocimiento, el desempeño operativo y el cumplimiento normativo.

A continuación, se presentan los requerimientos organizados por categorías.

Seguridad de la Información

1. **[RNF-01] Protección de datos mediante cifrado:** El sistema deberá garantizar la protección de los datos mediante mecanismos de cifrado tanto en almacenamiento como en transmisión.
2. **[RNF-02] Control de acceso basado en roles (RBAC):** El sistema deberá implementar un modelo de control de acceso que restringe las funcionalidades según el perfil del usuario.
3. **[RNF-03] Aislamiento de entornos:** El sistema deberá garantizar la separación entre entornos de validación y producción.

Trazabilidad y Auditabilidad

1. **[RNF-04] Registro de interacciones del sistema:** El sistema deberá registrar las consultas, respuestas y fuentes utilizadas en cada interacción.
2. **[RNF-05] Registro de intervenciones humanas:** El sistema deberá registrar todas las decisiones de validación realizadas por los usuarios autorizados.

Desempeño (Performance)

1. **[RNF-06] Tiempo de respuesta del sistema:** El sistema deberá responder a las consultas dentro de un tiempo adecuado (menos de 4 segundos) para la interacción del usuario.
2. **[RNF-07] Procesamiento asíncrono de evaluaciones:** El sistema deberá ejecutar los procesos de evaluación sin bloquear la respuesta al usuario.
3. **[RNF-08] Tiempo de ejecución de procesos ETL:** El sistema deberá completar los procesos de actualización dentro de tiempos definidos.

Disponibilidad y Confiabilidad

1. **[RNF-9] Tolerancia a fallos en procesos críticos:** El sistema deberá implementar mecanismos de recuperación ante fallos en procesos automatizados.
2. **[RNF-10] Actualización sin interrupción del servicio:** El sistema deberá permitir la actualización del conocimiento sin afectar la disponibilidad.

Gobernanza del Conocimiento

1. **[RNF-11] Versionado del conocimiento:** El sistema deberá mantener versiones identificables de la base de conocimiento.
2. **[RNF-12] Capacidad de reversión (rollback):** El sistema deberá permitir restaurar versiones anteriores del conocimiento.
3. **[RNF-13] Integridad de metadatos:** El sistema deberá garantizar la consistencia y validez de los metadatos asociados al conocimiento.

Escalabilidad

1. **[RNF-14] Escalabilidad del sistema:** El sistema deberá soportar incrementos en el volumen de datos y consultas.

Cumplimiento Normativo

1. **[RNF-15] Eliminación de datos personales:** El sistema deberá permitir la eliminación de información sensible cuando sea requerido.
2. **[RNF-16] Control de soberanía de datos:** El sistema deberá garantizar que la información no sea transferida a entornos no autorizados.
3. **[RNF-17] Trazabilidad de las respuestas generadas:** El sistema deberá garantizar que todas las respuestas puedan vincularse a fuentes verificables.

Priorización de Requerimientos

La priorización de requerimientos constituye un proceso metodológico orientado a determinar el orden de implementación y el grado de criticidad de las funcionalidades del sistema. En el caso de la arquitectura LLMOps propuesta, se adopta el método MoSCoW (Must Have, Should Have, Could Have), adaptado a las exigencias de un entorno regulado de alta criticidad. El criterio de priorización se fundamenta en los siguientes ejes:

- **Criticidad del dominio:** necesidad de garantizar respuestas precisas, trazables y confiables.
- **Cumplimiento normativo:** adecuación a la Ley N.º 25.326 y a los principios de protección de datos.
- **Impacto operativo:** contribución al funcionamiento del ciclo cerrado (*closed-loop*), especialmente en la detección y corrección de degradaciones.

En función de estos criterios, se establecen las siguientes categorías:

- **Must Have (Críticos):** requerimientos indispensables para la viabilidad técnica, operativa y legal del sistema.
- **Should Have (Importantes):** requerimientos que aportan valor significativo y fortalecen el modelo LLMOps, aunque su ausencia no impide la operación básica.
- **Could Have (Deseables):** requerimientos orientados a la optimización y mejora de la experiencia, cuya implementación puede postergarse.

A continuación, se presenta una selección representativa de requerimientos priorizados:

Tabla 4. Priorización de requerimientos

ID	Tipo	Descripción	Prioridad
RF-03	RF	Generación de respuesta basada en contexto	<i>Must Have</i>
RF-04	RF	Inclusión de referencias documentales	<i>Must Have</i>
RF-19	RF	Validación humana previa a actualización	<i>Must Have</i>
RNF-01	RNF	Protección de datos mediante cifrado	<i>Must Have</i>
RNF-02	RNF	Control de acceso basado en roles	<i>Must Have</i>
RNF-16	RNF	Eliminación de datos personales	<i>Must Have</i>
RNF-17	RNF	Control de soberanía de datos	<i>Must Have</i>
RF-07	RF	Evaluación semántica de respuestas	<i>Should Have</i>
RF-10	RF	Detección de degradación (drift)	<i>Should Have</i>
RF-16	RF	Ingesta y vectorización en staging	<i>Should Have</i>
RNF-07	RNF	Tiempo de respuesta del sistema	<i>Should Have</i>
RF-21	RF	Visualización de métricas	<i>Could Have</i>

Trazabilidad de Requerimientos

La trazabilidad de requerimientos permite establecer relaciones entre los distintos artefactos del proceso de desarrollo, vinculando los casos de uso con los requerimientos funcionales y no

funcionales. En el contexto de la arquitectura propuesta, la trazabilidad adquiere un rol central al permitir:

- Relacionar cada funcionalidad con necesidades específicas del dominio
- Analizar el impacto de modificaciones en los modelos o en el conocimiento
- Facilitar auditorías técnicas y normativas

A continuación, se presenta una matriz de trazabilidad simplificada, que vincula los principales casos de uso con los requerimientos asociados:

Tabla 5. Matriz de trazabilidad

Caso de Uso	Requerimientos Funcionales	Requerimientos No Funcionales
CU-01: Consulta RAG	<i>RF-01, RF-02, RF-03, RF-04</i>	<i>RNF-07, RNF-18</i>
CU-02: Evaluación	<i>RF-05, RF-06, RF-07, RF-08</i>	<i>RNF-08</i>
CU-03: Detección de drift	<i>RF-09, RF-10, RF-11</i>	<i>RNF-06</i>
CU-04: Actualización ETL	<i>RF-13, RF-14, RF-15, RF-16</i>	<i>RNF-09, RNF-10</i>
CU-05: Validación HITL	<i>RF-17, RF-18, RF-19</i>	<i>RNF-02, RNF-05, RNF-11</i>

Cierre de la Ingeniería de Requerimientos

La presente sección ha permitido formalizar de manera estructurada las necesidades identificadas en el análisis previo, traduciéndolas en un conjunto coherente de requerimientos funcionales y no funcionales para la arquitectura LLMOps propuesta.

A partir de la identificación de los stakeholders y la definición de los escenarios de uso, se logró establecer una comprensión integral del sistema como un entorno sociotécnico. Esta visión permitió derivar requerimientos que no solo contemplan la generación de respuestas, sino también su evaluación, monitoreo y actualización continua. Asimismo, la incorporación de requerimientos no funcionales vinculados a la seguridad, la trazabilidad, el desempeño y la gobernanza del conocimiento

refuerza la orientación del sistema hacia entornos de alta criticidad, donde la confiabilidad y el cumplimiento normativo constituyen condiciones indispensables. La priorización de requerimientos permitió identificar aquellos elementos críticos para la viabilidad del sistema, mientras que la matriz de trazabilidad aseguró la coherencia entre los casos de uso y las especificaciones técnicas.

En conjunto, este proceso de ingeniería de requerimientos establece una base sólida y consistente para el diseño de la arquitectura del sistema, garantizando que las decisiones técnicas posteriores se encuentren alineadas con las necesidades del dominio, las exigencias normativas y los objetivos de confiabilidad planteados.

